



# Teorie kognitivních systémů

## 2 Lineární regrese – I

- Lineární regrese jedné proměnné
- Odvození cenové funkce
- Minimalizace cenové funkce
- Odvození gradientní metody
- Algoritmus gradientního sestupu





# Lineární regrese

## Nejjednodušší algoritmus učení s učitelem

- myšlenky vychází z „předpočítáčového“ období statistiky
- nejjednodušší algoritmus → na praktické úlohy z oblasti UI obvykle nepoužitelný, ale představuje základní stavební prvek a **pochopitelným způsobem demonstruje fundamentální myšlenky techniky regrese**
- jednoduchá, tj. poskytuje snadno interpretovatelný popis toho, jak vstupní data ovlivňují data výstupní
- při predikci často překonává komplikovanější nelineární metody, zejména je-li málo trénovacích dat, jsou-li data znehodnocená šumem nebo velmi řídká
- lineární regresi lze aplikovat na transformace vstupních dat, což značně rozšiřuje možnosti využití → **metody bázových funkcí (Basis-Function Methods)**, např. RBF, GRBF, ...



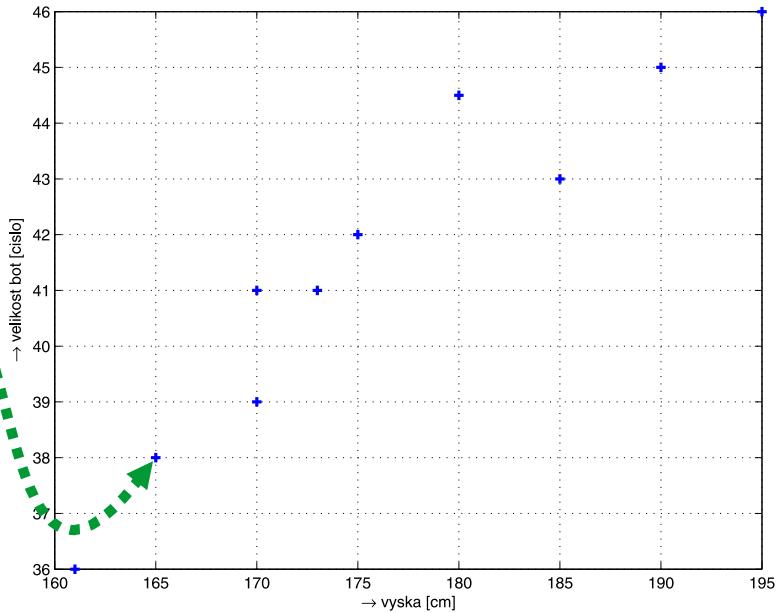


# Lineární regrese

## Motivační příklad

Závislost čísla bot  
na výšce osoby

- učení s učitelem  
(známe „správné“ odpovědi v trénovací množině)
- regresní úloha  
(odhadovaný výstup je spojitý)

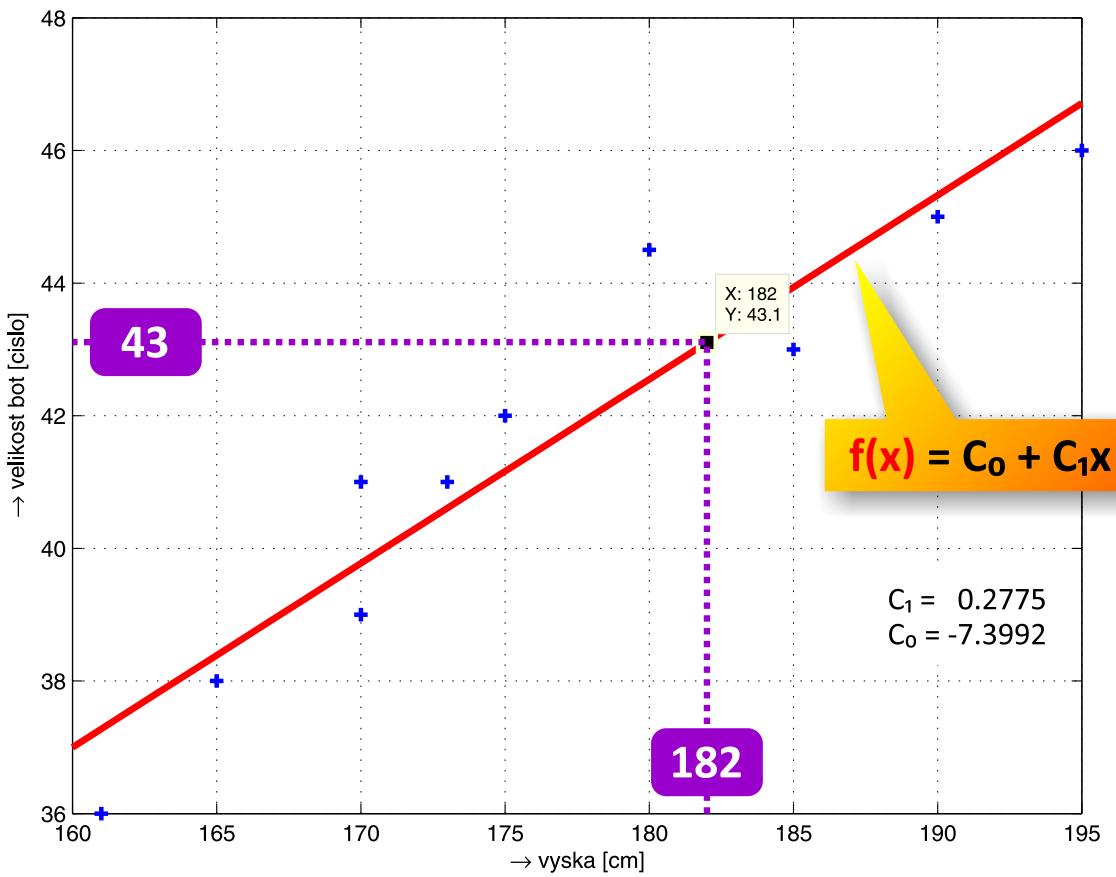


➔ potřebujeme data proložit **lineární funkcí** tak, abychom mohli pro libovolnou hodnotu vstupu (tj. výšky osoby na ose x) předpovědět velikost obuvi...



# Lineární regrese

## Motivační příklad





# Lineární regrese

## Motivační příklad – trénovací množina

**Trénovací množina** – pozorované páry (výška osoby, velikost obuvi)

**Trénovací vzorek** – např.  $(x^{(5)}, y^{(5)})$

**Značení:**

$m$  – celkový počet trénovacích vzorků (tj. velikost trénovací množiny čili počet řádek)

$x$  – vstup (proměnná, obecně vektor příznaků)

$y$  – výstup (proměnná, obvykle skalární výsledná predikovaná hodnota)

shoes <10x2 double>

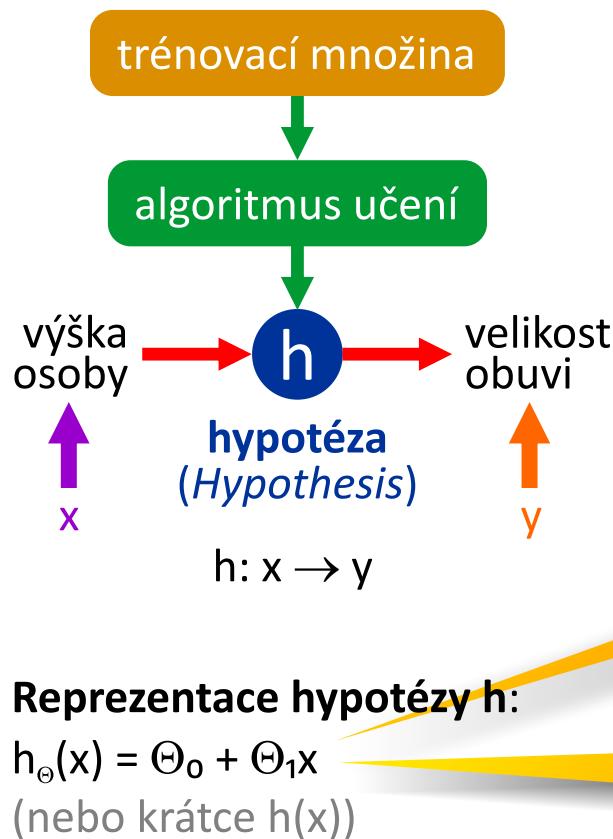
	1	2
1	161	36
2	165	38
3	170	39
4	170	41
5	173	41
6	175	42
7	180	44.5000
8	185	43
9	190	45
10	195	46

↑  $x^{(i)}$       ↑  $y^{(i)}$



# Lineární regrese

## Schéma učení s učitelem



Lineární regrese jedné proměnné (*Univariate Linear Regression*)

**Reprezentace hypotézy  $h$ :**  
 $h_{\Theta}(x) = \Theta_0 + \Theta_1 x$   
(nebo krátce  $h(x)$ )

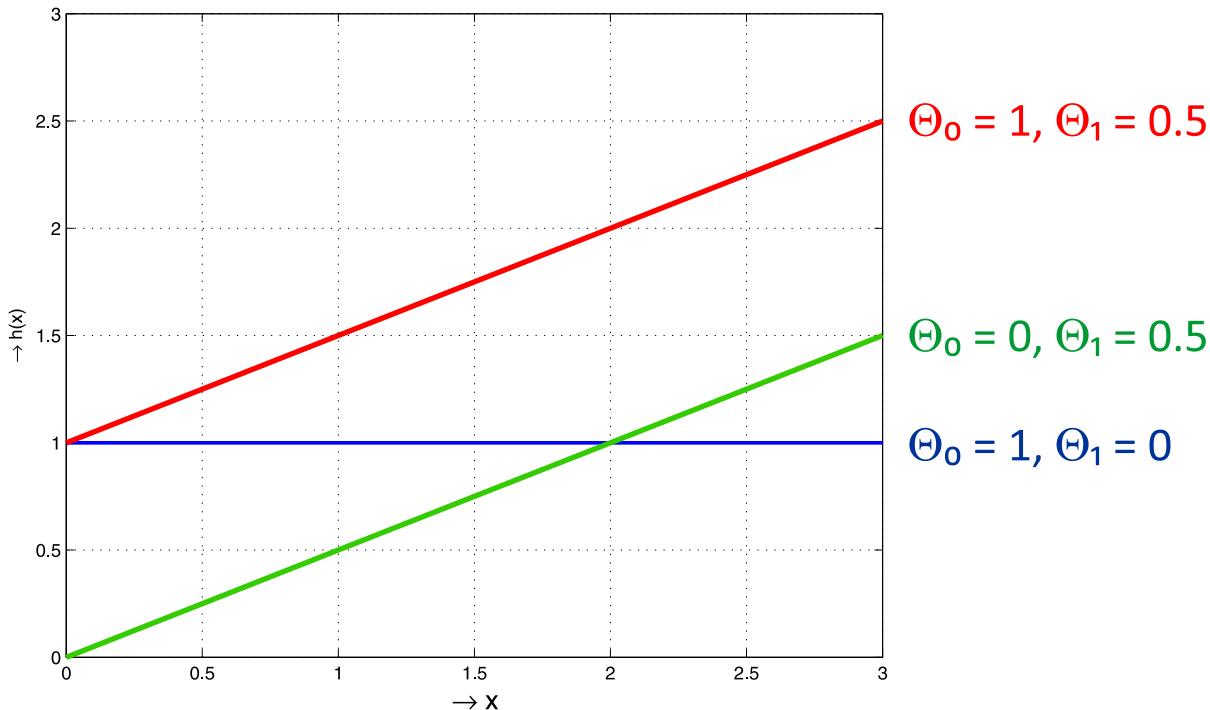
Matematický model hypotézy závisí na 2 parametrech  $\Theta_0, \Theta_1$



# Cenová funkce

## Jak nastavit parametry hypotézy?

Hypotéza  $h_{\Theta}(x)$  má tvar lineární funkce  $h_{\Theta}(x) = \Theta_0 + \Theta_1 x$ , tj.:





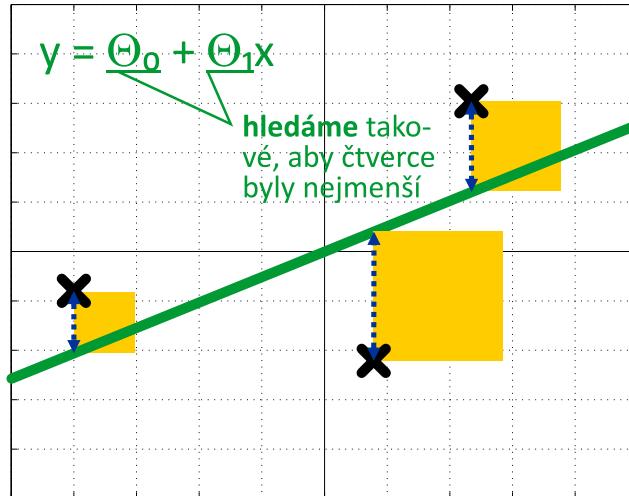
# Cenová funkce

## Jak nastavit parametry hypotézy?

**Základní myšlenka:** stanovit  $\Theta_0, \Theta_1$  tak, aby hodnoty predikované hypotézou  $h_{\Theta}(x)$  pro  $x^{(i)}$  z trénovací množiny byly **co nejblíže** hodnotám  $y^{(i)}$

z trénovací množiny:

$$\arg \min_{\Theta_0, \Theta_1} \left( \frac{1}{2m} \sum_{i=1}^m (h_{\Theta}(x^{(i)}) - y^{(i)})^2 \right)$$



$$J(\Theta_0, \Theta_1)$$

**cenová funkce**  
*(Cost Function)*

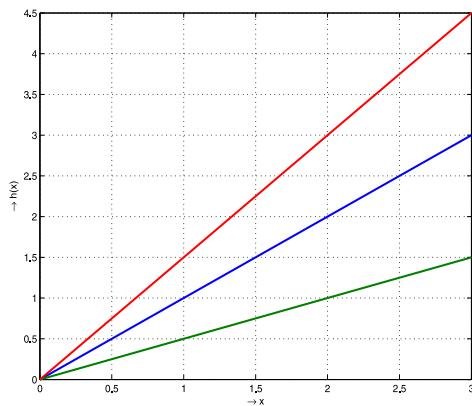
→ hledáme takové parametry  $\Theta_0$  a  $\Theta_1$ , pro které nabývá  $J(\Theta_0, \Theta_1)$  minima...



# Cenová funkce

## Odvození – zjednodušená varianta

Pro získání představy o fungování cenové funkce zjednodušíme hypotézu na tvar  $h_{\Theta}(x) = \Theta_1 x$  (bude procházet počátkem s. s.):



**Cenová funkce** bude pak mít tento tvar:

$$\begin{aligned} J(\Theta_1) &= \frac{1}{2m} \sum_{i=1}^m (h_{\Theta}(x^{(i)}) - y^{(i)})^2 \\ &= \frac{1}{2m} \sum_{i=1}^m (\Theta_1 x^{(i)} - y^{(i)})^2 \end{aligned}$$

Tuto cenovou funkci budeme minimalizovat, abychom našli optimální nastavení parametru  $\Theta_1$ ...

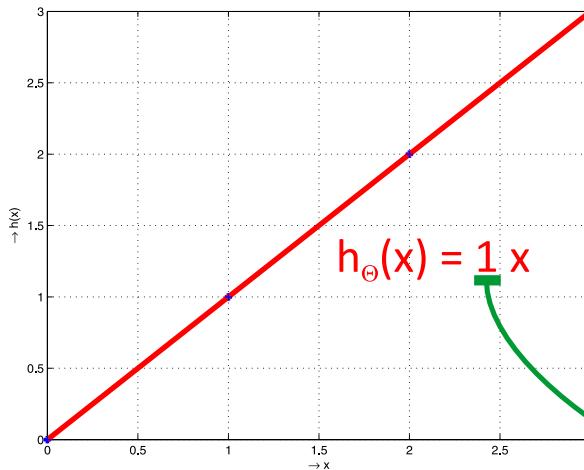


# Cenová funkce

## Odvození – zjednodušená varianta

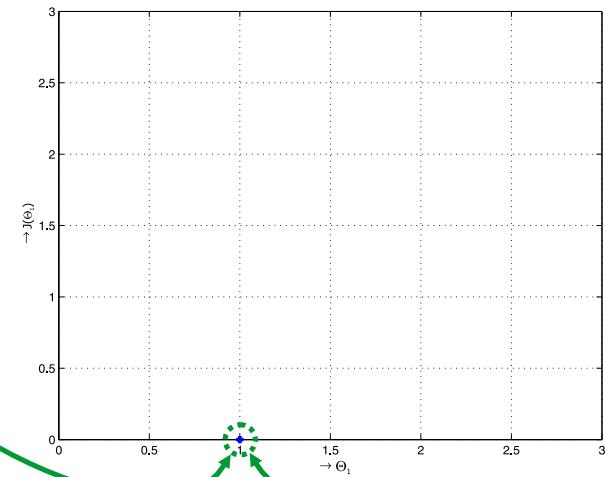
$$h_{\Theta}(x)$$

(pro dané  $\Theta_1$  je funkcí x)



$$J(\Theta_1)$$

(funkce parametru  $\Theta_1$ )



$$J(\Theta_1) = \frac{1}{2m} \sum_{i=1}^m (\Theta_1 x^{(i)} - y^{(i)})^2 = \frac{1}{2 \cdot 3} (0^2 + 0^2 + 0^2) = 0$$

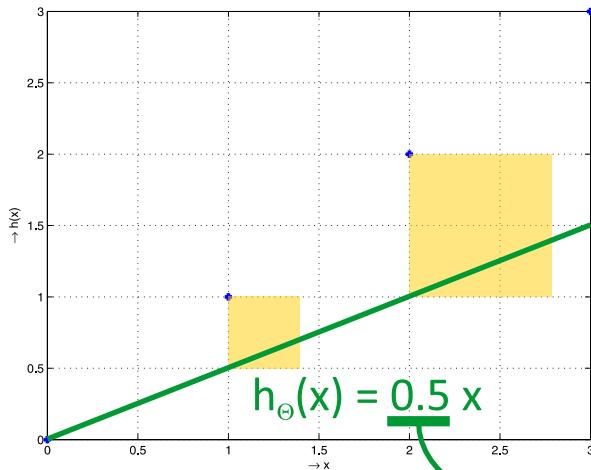


# Cenová funkce

## Odvození – zjednodušená varianta

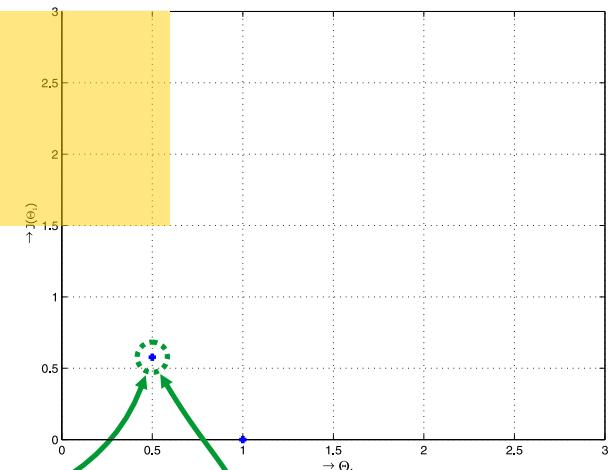
$$h_{\Theta}(x)$$

(pro dané  $\Theta_1$  je funkcí x)



$$J(\Theta_1)$$

(funkce parametru  $\Theta_1$ )



$$J(\Theta_1) = \frac{1}{2 \cdot 3} \left( \left(\frac{1}{2}\right)^2 + 1^2 + \left(\frac{3}{2}\right)^2 \right) = 0.583$$

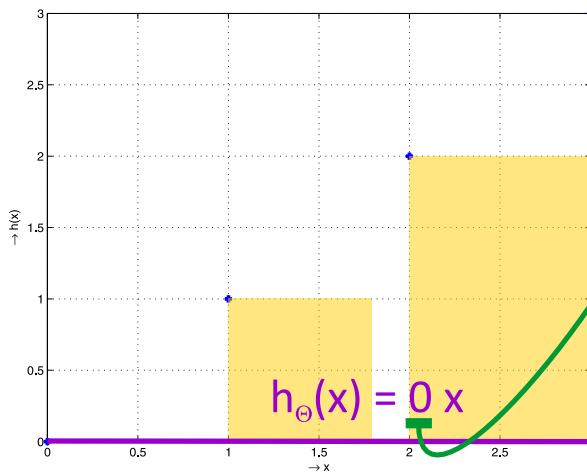


# Cenová funkce

## Odvození – zjednodušená varianta

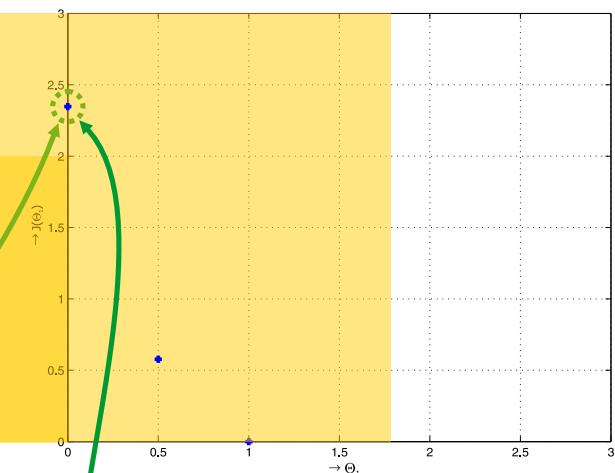
$$h_{\Theta}(x)$$

(pro dané  $\Theta_1$  je funkcí x)



$$J(\Theta_1)$$

(funkce parametru  $\Theta_1$ )



$$J(\Theta_1) = \frac{1}{2 \cdot 3} (1^2 + 2^2 + 3^2) = 2.\overline{3}$$

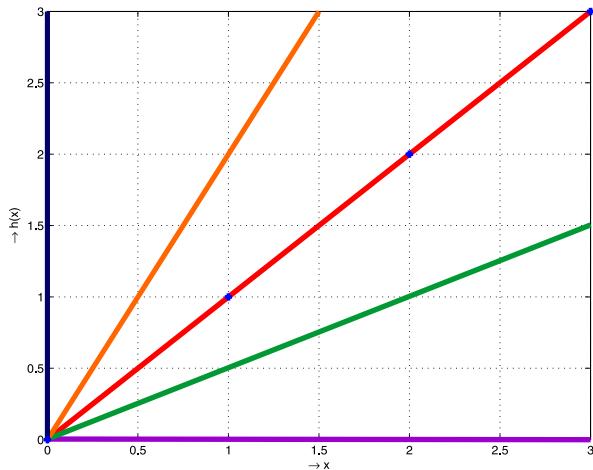


# Cenová funkce

## Odvození – zjednodušená varianta

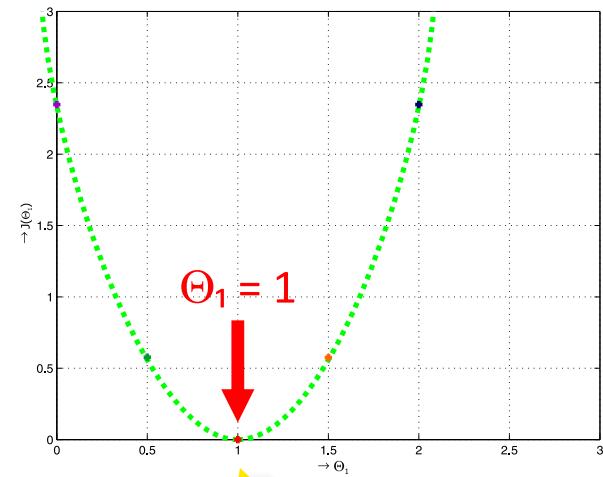
$$h_{\Theta}(x)$$

(pro dané  $\Theta_1$  je funkcí x)



$$J(\Theta_1)$$

(funkce parametru  $\Theta_1$ )



$$\arg \min_{\Theta_1} J(\Theta_1) = 1$$



# Cenová funkce

## Odvození – varianta pro příklad s obuví

- **hypotéza** má tvar  $h_{\Theta}(x) = \Theta_0 + \Theta_1 x$
- **parametry** jsou tedy  $\Theta_0, \Theta_1$
- **cenová funkce** je  $J(\Theta_0, \Theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\Theta}(x^{(i)}) - y^{(i)})^2$
- cílem **optimalizace** je nalézt takové argumenty  $\Theta_0, \Theta_1$  cenové funkce  $J(\Theta_0, \Theta_1)$ , aby pro ně funkce nabývala minima, tj. minimalizace funkce  $J(\Theta_0, \Theta_1)$ , neboli:

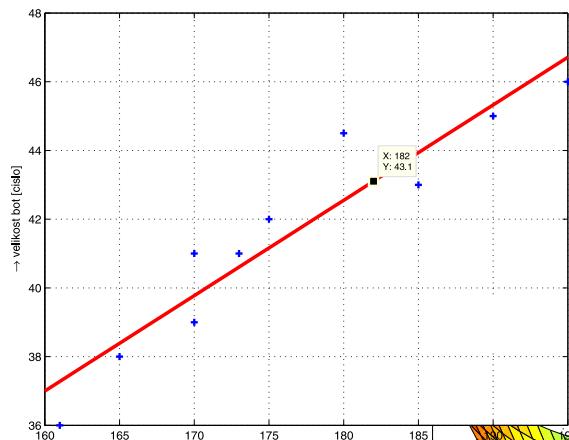
$$\arg \min_{\Theta_0, \Theta_1} \left( \frac{1}{2m} \sum_{i=1}^m (h_{\Theta}(x^{(i)}) - y^{(i)})^2 \right)$$





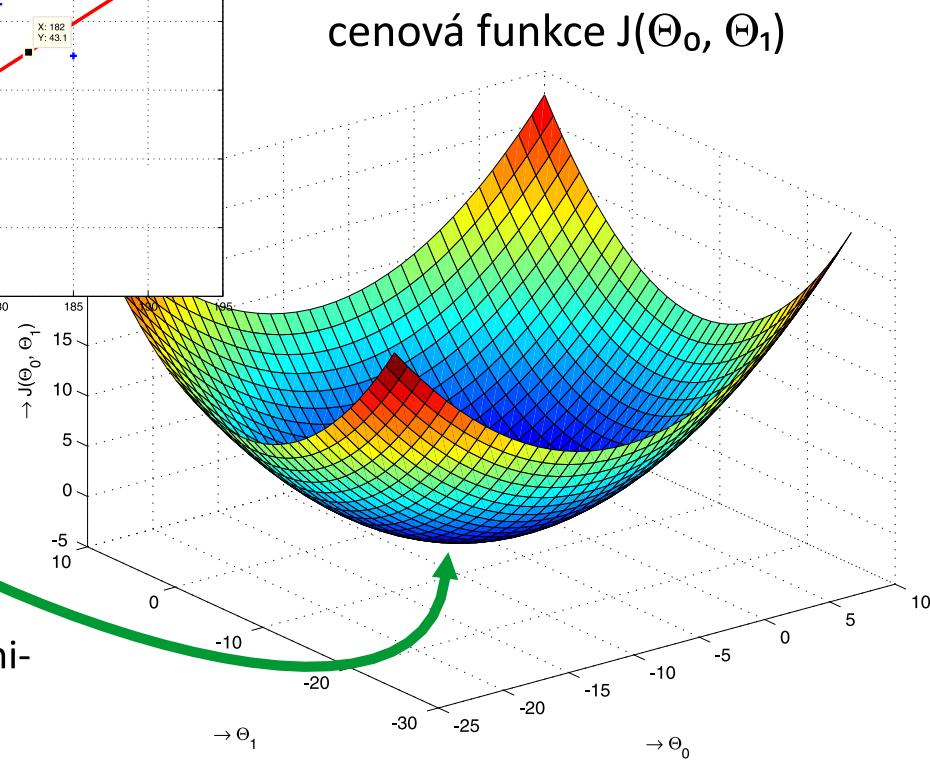
# Cenová funkce

## Odvození – varianta pro příklad s obuví



$$\Theta_0 = -7.3992$$
$$\Theta_1 = 0.2775$$

cenová funkce nabývá minima na souřadných (-7.3992, 0.2775)



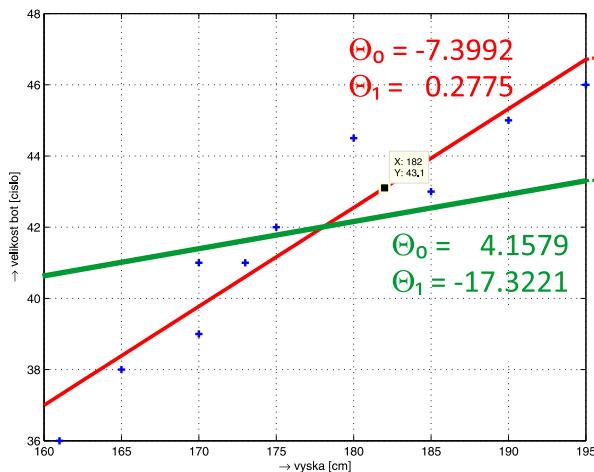


# Cenová funkce

Odvození – varianta pro příklad s obuví

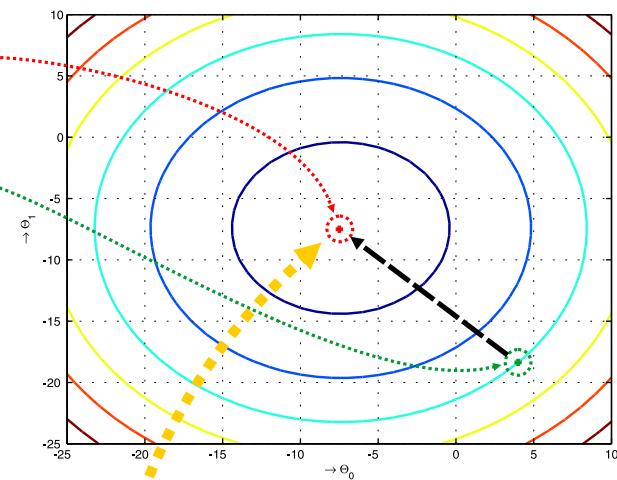
$$h_{\Theta}(x)$$

(pro dané  $\Theta_0, \Theta_1$  je funkcí x)



$$J(\Theta_0, \Theta_1)$$

(funkce parametrů  $\Theta_0, \Theta_1$ )



Jak nalézt (numericky) minimum cenové funkce  $J(\Theta_0, \Theta_1)$ ?

Pomocí techniky gradientního sestupu (Gradient Descent)...



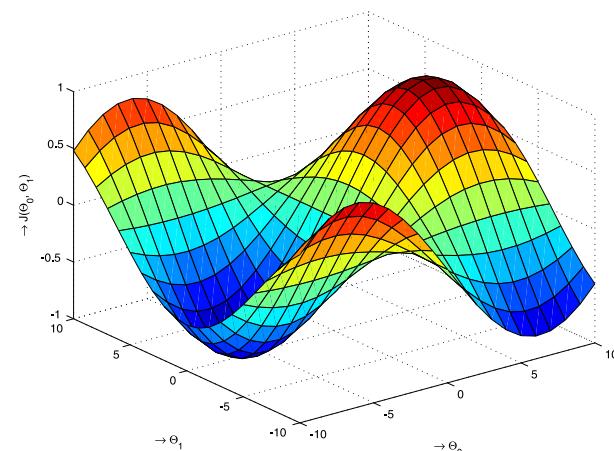
# Gradientní sestup (*Gradient Descent*)

## Nástin algoritmu

Je **dána** cenová funkce  $J(\Theta_0, \Theta_1)$  nebo obecně  $J(\Theta_0, \dots, \Theta_n)$ . Chceme najít hodnoty  $\Theta_i$ , pro které **nabývá minima**.

### Postup:

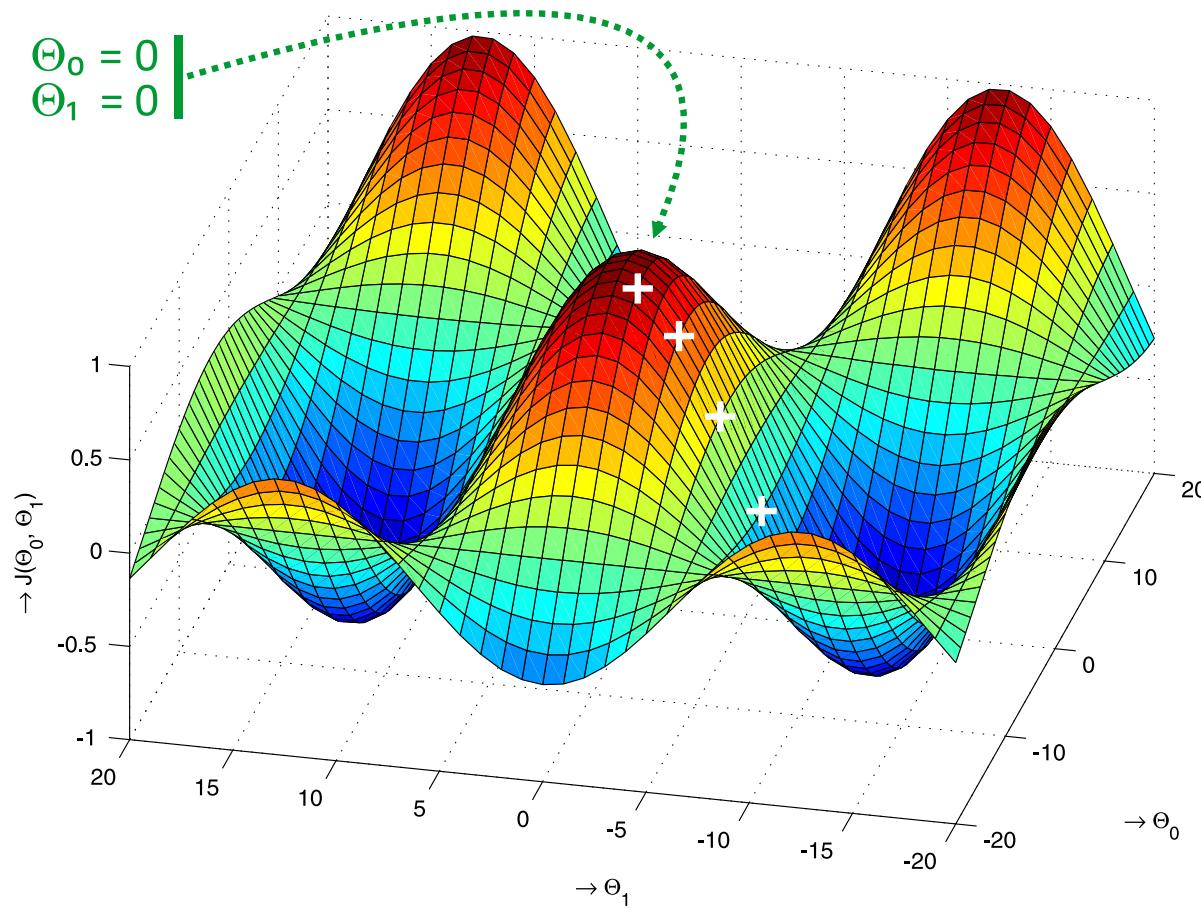
- začneme s nějakými hodnotami  $\Theta_i$ , např. 0 nebo náhodnými
- měníme hodnoty  $\Theta_i$  tak, aby se snižovala funkční hodnota cenové funkce  $J(\Theta_0, \dots, \Theta_n)$ , dokud nenalezneme její **minimum** (snad)





# Gradientní sestup (*Gradient Descent*)

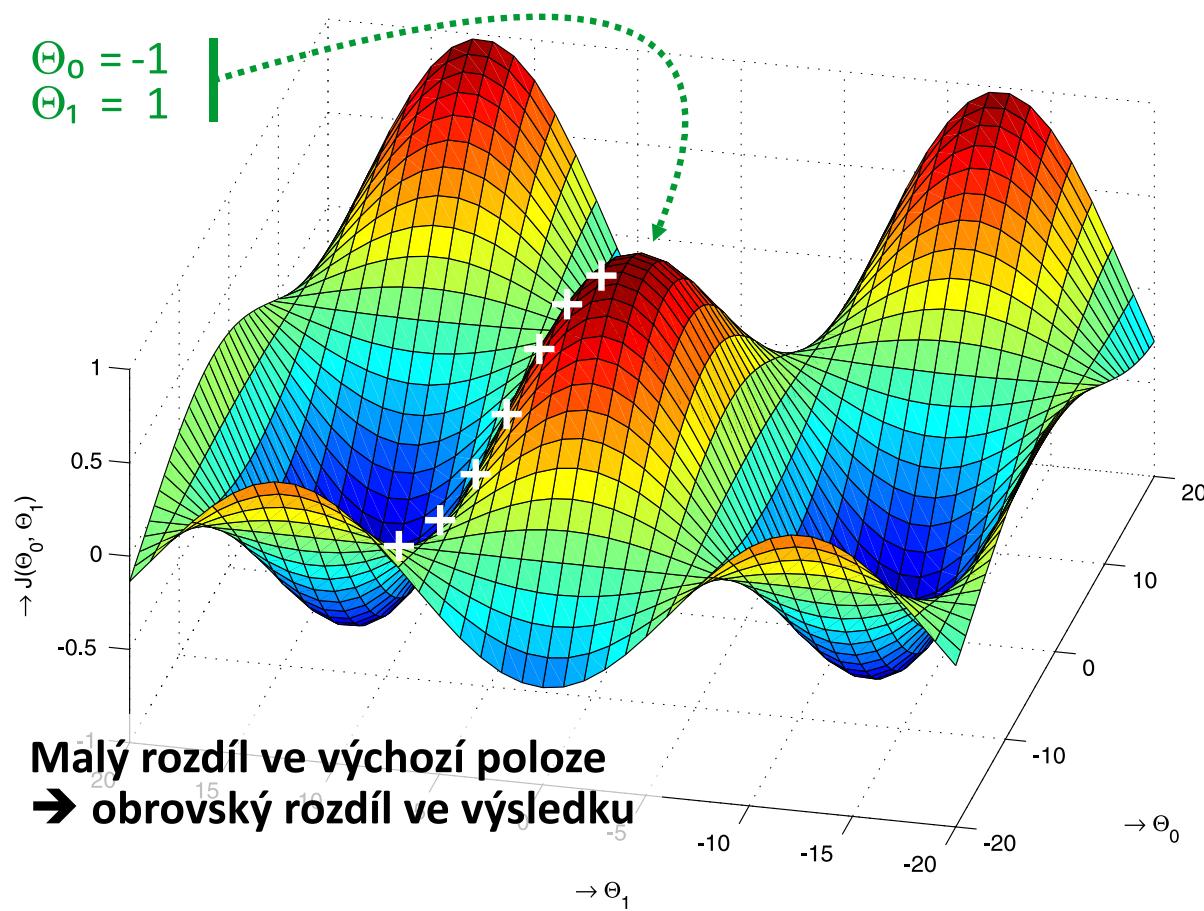
## Problém algoritmu – lokalita extrému





# Gradientní sestup (Gradient Descent)

## Problém algoritmu – lokalita extrému





# Algoritmus gradientního sestupu v pseudokódu

```
while not converged() do {
```

```
    for i = 1 .. n do  $\Theta_i \leftarrow \Theta_i - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_i}$ 
```

```
}
```



✓  $\text{temp}[0] = \Theta_0 - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_0}$

:

$\text{temp}[n] = \Theta_n - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_n}$

---

$\Theta_0 = \text{temp}[0]$

:

$\Theta_n = \text{temp}[n]$

úprava hodnot  $\Theta_i$  musí proběhnout „současně“ (výpočtem ze stejných hodnot parametrů funkce J)

✗  $\text{temp}[0] = \Theta_0 - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_0}$

$\Theta_0 = \text{temp}[0]$

:

$\text{temp}[n] = \Theta_n - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_n}$

$\Theta_n = \text{temp}[n]$



# Algoritmus gradientního sestupu

## Matematický rozbor

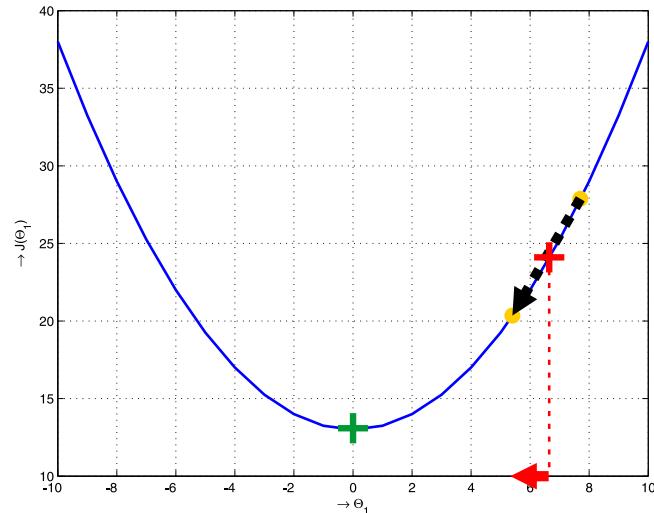
Úprava hodnot parametrů  $\Theta_i$ :

$$\Theta_i \leftarrow \Theta_i - \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_i} \cdot \alpha$$

míra učení  
(*Learning Rate*)

parciální derivace  
(*Partial Derivative*)

Geometrická interpretace  
derivace funkce v bodě:





# Algoritmus gradientního sestupu

## Matematický rozbor

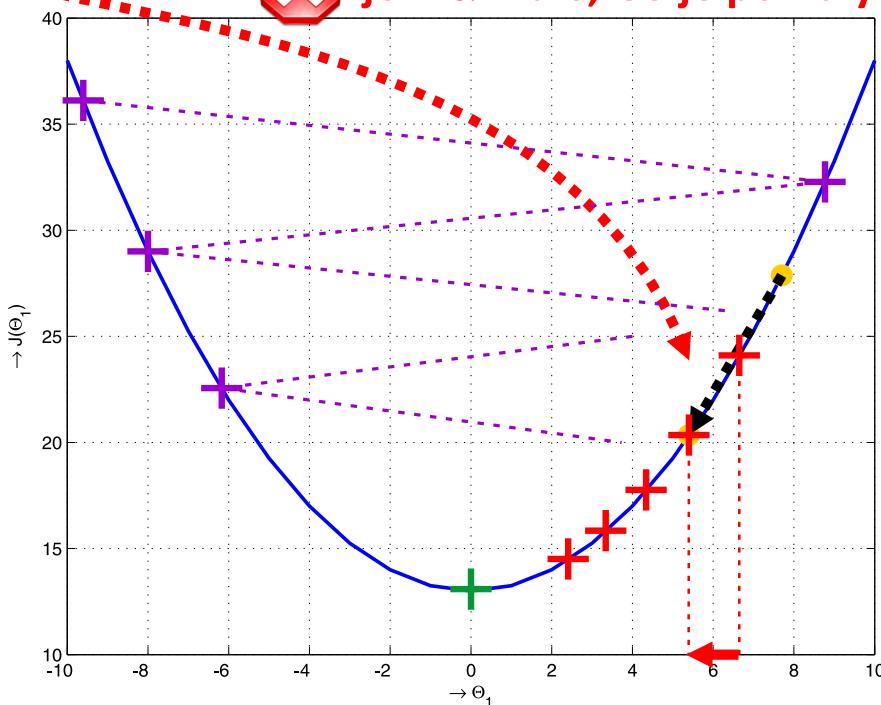
$$\Theta_i \leftarrow \Theta_i - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_i}$$



je-li  $\alpha$  velké,  
GS „přestře-  
luje“ správnou  
pozici extrému  
– může diver-  
govat...



je-li  $\alpha$  malé, GS je pomalý

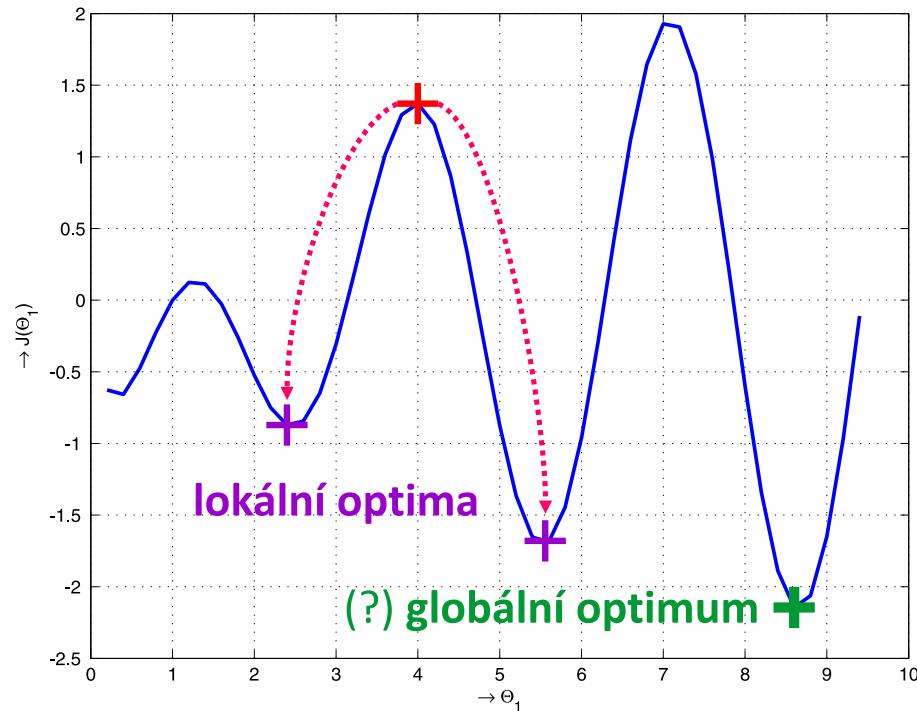




# Algoritmus gradientního sestupu

## Matematický rozbor – lokalita extrému

$$\Theta_i \leftarrow \Theta_i - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_i}$$





# Algoritmus gradientního sestupu

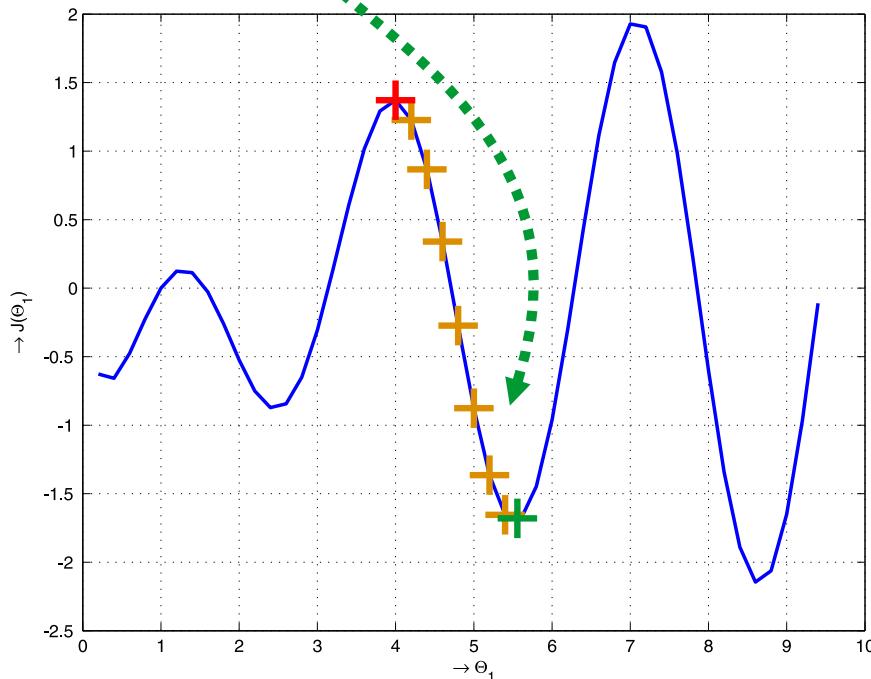
## Matematický rozbor – konvergence

$$\Theta_i \leftarrow \Theta_i - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_i}$$

vlastnost derivace

**GS konverguje k lokálnímu minimu i tehdy, je-li  $\alpha = C...$**

Jak se blížíme k lokálnímu minimu, krok GS se zmenšuje, tj. není nutné  $\alpha$  adaptivně upravovat...





# Gradientní sestup pro potřeby lineární regrese

$$\Theta_i \leftarrow \Theta_i - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_i}$$

je třeba vyjádřit a spočítat tuto derivaci...

derivace složené funkce!

$$\begin{aligned} \frac{\partial J(\Theta_0, \Theta_1)}{\partial \Theta_{0\dots 1}} &= \frac{\partial}{\partial \Theta_{0\dots 1}} \frac{1}{2m} \sum_{i=1}^m \left( h_\Theta(x^{(i)}) - y^{(i)} \right)^2 \\ &= \frac{\partial}{\partial \Theta_{0\dots 1}} \frac{1}{2m} \sum_{i=1}^m \left( \Theta_0 + \Theta_1 x^{(i)} - y^{(i)} \right)^2 \end{aligned}$$

pro  $\Theta_0$ : 
$$\frac{\partial J(\Theta_0, \Theta_1)}{\partial \Theta_0} = \frac{1}{m} \sum_{i=1}^m \left( h_\Theta(x^{(i)}) - y^{(i)} \right)$$

pro  $\Theta_1$ : 
$$\frac{\partial J(\Theta_0, \Theta_1)}{\partial \Theta_1} = \frac{1}{m} \sum_{i=1}^m \left( h_\Theta(x^{(i)}) - y^{(i)} \right) \cdot x^{(i)}$$



# Gradientní sestup

## pro potřeby lineární regrese – algoritmus

```
while not converged() do {  
    temp[0] ← Θ₀ - α  $\frac{1}{m} \sum_{i=1}^m (h_\Theta(x^{(i)}) - y^{(i)})$   
    temp[1] ← Θ₁ - α  $\frac{1}{m} \sum_{i=1}^m (h_\Theta(x^{(i)}) - y^{(i)}) \cdot x^{(i)}$   
    Θ₀ ← temp[0]  
    Θ₁ ← temp[1]  
}
```

**Dávkový gradientní sestup (Batch Gradient Descent) –**  
v každém kroku sestupu se výpočet provádí se všemi dostupnými trénovacími vzorky...