




# Teorie kognitivních systémů

## 4 Logistická regrese

- Logistická regrese
- Model hypotézy pro LogR
- Interpretace výsledků
- Rozhodovací hranice
- Cenová funkce pro LogR
- Klasifikace do více tříd
- Algoritmus One vs All





# Logistická regrese

## Regres pro predikci diskrétních hodnot

- predikovaná proměnná  $y = h_{\Theta}(x)$  nabývá diskrétních hodnot: buď 0 nebo 1 – **binomická** či **binární logistická regrese**, nebo 0 až K – **multinomická logistická regrese (MNL)** nebo také logistická regrese s vícekategoriální vysvětlovanou proměnnou, tj. jedná se o **klasifikační úlohu**
- predikovaná proměnná (čili modelovaná veličina) má tzv. **alternativní rozdělení p-sti (Bernoulli Distribution)** – jde o variantu binomického rozdělení  $Bi(n, p)$ , kde počet pokusů  $n = 1$  a p je p-st úspěchu (čili proměnná nabýde hodnoty 1)
- **jeden z nejpopulárnějších a nejrozšířenějších učících se algoritmů**, řada dalších technik z oblasti UI a strojového učení je na ní založena





# Logistická regrese

## Příklady klasifikačních úloh

Binární logistická regrese –

$$y = h_{\Theta}(x) \in \{0; 1\}$$

0: negativní třída  
1: pozitivní třída

- E-mail: spam / ne-spam
- Lékařská diagnostika nádorů: zhoubný / nezhoubný
- Bezpečnost (IS): autentizovaný / neautentizovaný přístup

$n$ -ární (multinomická) lineární regrese –

$$y = h_{\Theta}(x) \in \mathbb{N} \cup \{0\}$$


- Lékařská diagnostika: angína / chřipka / rýmička / kašel / ...  
např. existující systém DXplain (<http://dxplain.org/dxp/dxp.pl>)



# Logistická regrese

## Motivační příklad – tribodiagnostika

Vyměnit  
součástku?



Co se stane při aplikaci již známého aparátu **lineární regrese**?  
Zkusme proložit data přímkou, tj. hypotéza  $h_{\Theta}(x) = \Theta_0 + \Theta_1 x$




# Logistická regrese

## Motivační příklad – tribodiagnostika

**Problém:** Hypotéza v tomto tvaru  
předpovídá hodnoty mimo  $<0, 1>$

Vyměnit součástku?



Klasifikaci provedeme prahováním hypotézy  $h_{\Theta}(x)$  hodnotou 0,5:  
pro  $h_{\Theta}(x) \geq 0,5$ :  $y \leftarrow 1$ ; pro  $h_{\Theta}(x) < 0,5$ :  $y \leftarrow 0$



# Logistická regrese

## Motivační příklad – tribodiagnostika

Můžeme mít štěstí a bude to nějak fungovat, ale mnohem častěji to **fungovat nebude**, a to zejména proto, že:


- byť jsou data (odpovědi učitele) v trénovací množině pouze z množiny {0; 1}, algoritmus předpovídá spojité hodnoty na intervalu  $(-\infty; \infty)$  → nevíme, co dělat s hodnotami mimo interval  $<0; 1>\dots$
- pro hodnoty  $h_{\Theta}(x) \in <0; 1>$  stanovíme práh na hodnotě 0.5 – to ale nemusí být správná hodnota prahu, prahem určená oddělující nadplocha neseparuje data z trénovací množiny správně podle pokynů učitele
- vyskytnou-li se v datech extrémní marginální hodnoty, pak takto navržený mechanismus klasifikace selže úplně (viz následující obr.)





# Logistická regrese

## Motivační příklad – tribodiagnostika





# Logistická regrese

## Vlastnosti

**Klasifikační úloha:**  $y \in \{0; 1\}$

**Lineární regrese:**  $y = h_{\Theta}(x) \in (-\infty; \infty)$

- omezení hypotézy na interval  $<0; 1>$  je problematické → není jednoznačné, nelze algoritmem LR určit/natrénovat, je velmi citlivé na extrémní marginální hodnoty v trénovací množině, atd.

**Logistická regrese:**  $y = h_{\Theta}(x) \in <0; 1>$

- ač se to z historických důvodů nazývá regrese, jedná se o **klasifikaci** (protože hypotéza logistické regrese predikuje z daného vstupu  $x$  pravděpodobnost, že  $y = 1$ )



# Logistická regrese


## Reprezentace hypotézy

Požadujeme  $0 \leq h_{\Theta}(x) \leq 1$ ,  
tj.  $h_{\Theta}(x) = P(\Theta^T x)$

reálné číslo

Hypotéza má tedy tvar:

$$h_{\Theta}(x) = \frac{1}{1 + e^{-\Theta^T x}}$$



– sigmoida je speciálním případem tzv. **logistické funkce**  
(*Logistic Function*) pro  $a = 1, m = 0, n = 1, \tau = 1$

$$f(t; a, m, n, \tau) = a \frac{1 + me^{-t/\tau}}{1 + ne^{-t/\tau}}$$



# Logistická regrese

## Interpretace výsledků hypotézy

$h_{\Theta}(x)$  – odhad **pravděpodobnosti**, že modelovaná veličina na-  
byde hodnoty 1 (tj. např. jev nastane), je-li vstupem  
vektor příznaků  $x$

**Příklad:** Při tribodiagnostice byla naměřena průměrná velikost  
částic kovu v oleji 3.27  $\mu$  – tzn. vstupem hypotézy bude

$$x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ 3.27 \end{bmatrix}$$

nutné, aby to šlo zapsat  
maticově jako soustavu

$$h_{\Theta}(x) = \frac{1}{1 + e^{-(\Theta_0 + \Theta_1 \cdot 3.27)}} = 0.79$$

Hypotéza říká, že při velikosti částic 3.27  $\mu$  je s **pravděpodob-  
ností 79% potřeba ložisko vyměnit.**



# Logistická regrese

## Statistická interpretace výsledků hypotézy

$h_{\Theta}(x)$  – pravděpodobnost, že  $y = 1$  za podmínky  $x$ , parametricky zovaná  $\Theta$ :

$$h_{\Theta}(x) = P(y = 1 \mid x; \Theta)$$

Z toho plynou některé zřejmé závěry:

$$P(y = 0 \mid x; \Theta) + P(y = 1 \mid x; \Theta) = 1, \text{ z čehož}$$

$$P(y = 0 \mid x; \Theta) = 1 - P(y = 1 \mid x; \Theta)$$

Tzn. v předchozím příkladu odhad pravděpodobnosti, že ložisko není třeba měnit, je  $1 - 0.79 = 0.21$ , tj. 21%





# Logistická regrese

## Chování modelu

**Hypotéza**  $h_{\Theta}(x) = P(\Theta^T x)$ , kde

$$P(t) = \frac{1}{1 + e^{-t}}$$

**Model predikuje:**

„y = 1“  $\Leftrightarrow h_{\Theta}(x) \geq 0.5$ , tj.


$$P(t) \geq 0.5$$


 $\Theta^T x \geq 0$ 


„y = 0“  $\Leftrightarrow h_{\Theta}(x) < 0.5$ , tj.

$$P(t) < 0.5$$


 $\Theta^T x < 0$ 



# Rozhodovací hranice (*Decision Boundary*)


## Chování LR v obrazovém prostoru

$$h_{\Theta}(x) = P(\Theta_0 + \Theta_1 x_1 + \Theta_2 x_2)$$

**rozhodovací hranice**

Zvolme  $\Theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$

(zatím neřešíme, jak  
 $\Theta$  „nastavit“)



Model predikuje „y = 1“  $\Leftrightarrow -3 + x_1 + x_2 \geq 0$ , čili když  $x_1 + x_2 \geq 3$ .  
 $\Theta^T x$

Naopak když  $x_1 + x_2 < 3$ , model predikuje „y = 0“.

Pokud právě  $x_1 + x_2 = 3 \Leftrightarrow h_{\Theta}(x) = 0.5$





# Rozhodovací hranice

## Nelineární rozhodovací hranice

Volbou tvaru a parametrů hypotézy můžeme vytvářet libovolně složité rozhodovací hranice:


Zvolme  $\Theta = \begin{bmatrix} -1 \\ 0 \\ 0 \\ 1 \\ 1 \end{bmatrix}$

$$h_{\Theta}(x) = P(\Theta_0 + \Theta_1 x_1 + \Theta_2 x_2 + \Theta_3 x_1^2 + \Theta_4 x_2^2)$$

Model predikuje „y = 1“  $\Leftrightarrow -1 + x_1^2 + x_2^2 \geq 0$

$$x_1^2 + x_2^2 \geq 1$$

**(ne)rovnice kružnice**





# Cenová funkce logistické regrese

## Odvození – výchozí podmínky

Trénovací množina o  $m$  vzorcích

$$T = \{(\mathbf{x}^{(1)}, y^{(1)}); (\mathbf{x}^{(2)}, y^{(2)}); \dots; (\mathbf{x}^{(m)}, y^{(m)})\}$$

$$\mathbf{x}^{(i)} = \begin{bmatrix} x_0^{(i)} \\ x_1^{(i)} \\ \vdots \\ x_n^{(i)} \end{bmatrix} \in \mathbb{R}^{n+1}, \forall i : x_0^{(i)} = 1; y \in \{0, 1\}$$

$$\text{Hypotéza } h_{\Theta}(\mathbf{x}) = \frac{1}{1 + e^{-\Theta^T \mathbf{x}}}$$

**Problém:** Jak nastavit parametry  $\Theta$ , aby algoritmus logistické regrese klasifikoval neznámé vzorky s nejmenší chybou?



# Cenová funkce logistické regrese

## Odvození

**Lineární regrese** – minimalizujeme cenovou funkci ve tvaru:


$$J(\Theta) = \frac{1}{m} \sum_{i=1}^m \frac{1}{2} \left( h_{\Theta}(\mathbf{x}^{(i)}) - y^{(i)} \right)^2$$

**Logistická regrese** – zavedeme funkci Cost:

$$J(\Theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}\left(h_{\Theta}(\mathbf{x}^{(i)}), y^{(i)}\right)$$

↓

$$\text{Cost}(h_{\Theta}(\mathbf{x}), y) = \frac{1}{2} (h_{\Theta}(\mathbf{x}) - y)^2$$



**nekonvexní funkce  
– GS nenaleze glob. optimum**

$$\frac{1}{1 + e^{-\Theta^T \mathbf{x}}}$$


**Je třeba nadefinovat cenovou funkci jinak, aby GS fungoval...**



# Cenová funkce logistické regrese

## Odvození

$$\text{Cost}(h_{\Theta}(\mathbf{x}), y) = \begin{cases} -\log(h_{\Theta}(\mathbf{x})) & \text{když } y = 1 \\ -\log(1 - h_{\Theta}(\mathbf{x})) & \text{když } y = 0 \end{cases}$$




max. penalizace v případě, že  $h_{\Theta}(\mathbf{x}) = 0$ , tj.  $P(y = 1 | \mathbf{x}; \Theta) = 0$ , ale přitom  $y = 1$ ...



# Cenová funkce logistické regrese

## Odvození

$$\text{Cost}(h_{\Theta}(\mathbf{x}), y) = \begin{cases} -\log(h_{\Theta}(\mathbf{x})) & \text{když } y = 1 \\ -\log(1 - h_{\Theta}(\mathbf{x})) & \text{když } y = 0 \end{cases}$$



Když predikce  
 $h_{\Theta}(\mathbf{x}) \rightarrow 0$ ,  
pak  $\text{Cost} \rightarrow \infty$

Je-li  $y = 0$  a  $h_{\Theta}(\mathbf{x}) = 0$ , pak je  
Cost rovno nule (žádná pe-  
nalizace)...



# Cenová funkce logistické regrese

## Zjednodušený zápis vhodný pro GS

**Cenová funkce**  $J(\Theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}\left(h_\Theta(\mathbf{x}^{(i)}), y^{(i)}\right)$

$$\text{Cost}\left(h_\Theta(\mathbf{x}), y\right) = \begin{cases} -\log(h_\Theta(\mathbf{x})) & \text{když } y = 1 \\ -\log(1 - h_\Theta(\mathbf{x})) & \text{když } y = 0 \end{cases}$$

**Přičemž vždy  $y \in \{0; 1\}$**  – to je významný poznatek, umožňující zjednodušit zápis cenové funkce:

$$\text{Cost}\left(h_\Theta(\mathbf{x}), y\right) = -y \log(h_\Theta(\mathbf{x})) - (1 - y) \log(1 - h_\Theta(\mathbf{x}))$$

Pro  $y = 1$ :  $\text{Cost}\left(h_\Theta(\mathbf{x}), y\right) = -\log(h_\Theta(\mathbf{x}))$

Pro  $y = 0$ :  $\text{Cost}\left(h_\Theta(\mathbf{x}), y\right) = -\log(1 - h_\Theta(\mathbf{x}))$



# Cenová funkce logistické regrese

## Zjednodušený zápis vhodný pro GS

$$\begin{aligned}\textbf{Cenová funkce } J(\Theta) &= \frac{1}{m} \sum_{i=1}^m \text{Cost}\left(h_{\Theta}\left(\mathbf{x}^{(i)}\right), y^{(i)}\right) = \\ &= -\frac{1}{m} \left[ \sum_{i=1}^m y^{(i)} \log\left(h_{\Theta}(\mathbf{x}^{(i)})\right) + (1 - y^{(i)}) \log\left(1 - h_{\Theta}(\mathbf{x}^{(i)})\right) \right]\end{aligned}$$

Tvar cenové funkce vychází z poznatků statistiky, z principů techniky zvané metoda maximální věrohodnosti (*Maximum Likelihood Estimation, MLE*):

- je **konvexní**

Odhad neznámých veličin z pozorovaných dat:  
1. formulace pravděpodobnostního modelu,  
2. ověření shody modelu s realitou.

Hledáme parametry  $\Theta$ , tzn. **minimalizujeme** výše uvedenou cenovou funkci  $J(\Theta)$ ...



# Gradientní sestup v případě logistické regrese

Potřebujeme minimalizovat cenovou funkci  $J(\Theta)$ , abychom našli optimální nastavení parametrů  $\Theta \rightarrow$  aplikujeme GS:

```
while not converged() do {
```

```
    for j = 0 .. n do
```

$$\Theta_j \leftarrow \Theta_j - \alpha \frac{1}{m} \sum_{i=1}^m \left( h_\Theta(\mathbf{x}^{(i)}) - y^{(i)} \right) \cdot x_j^{(i)}$$

```
}
```

$$h_\Theta(\mathbf{x}) = \frac{1}{1 + e^{-\Theta^\top \mathbf{x}}}$$

Algoritmus vypadá stejně (a taky **stejný je**) jako v případě lineární regrese, až na tvar hypotézy  $h_\Theta(\mathbf{x})$ ...



# Pokročilejší optimalizační algoritmy pro výpočet parametrů logistické regrese

GS je tzv. „baseline“ – základní, nejméně sofistikovaná podoba optimalizačního algoritmu (viz přednáška Lineární regrese – asymptotická míra konvergence).

Ovšem implementujeme-li GS, musíme naprogramovat výpočet **cenové funkce  $J(\Theta)$**  – pro potřeby sledování konvergence, a její **parciální derivace** – pro potřeby výpočtu kroku GS...

Toto lze využít při aplikaci pokročilejších algoritmů:

- **Konjugovaný GS (Conjugate GD)**
- **BFGS (Broyden-Fletcher-Goldfarb-Shanno)**
- **L-BFGS (Limited-memory BFGS)**

} značně komplikované

**Výhody:** mnohem rychlejší konvergence, není třeba volit α





# Pokročilejší optimalizační algoritmy

## Implementace

Není příliš rozumné implementovat pokročilejší optimalizační algoritmy (CGD, BFGS, L-BFGS) vlastními silami – existuje řada knihoven (JProGraM, netlib, SciPy, HANSO, ...)

V MATLABu/Octave:

- funkce FMINUNC (Function Minimisation Unconstrained)
  - „nadopovaný“ gradientní sestup

UKÁZKA



# Klasifikace pomocí LogR do více tříd

## Algoritmus „One vs All“


Klasifikace do více tříd (*Multiclass Classification*) –

Predikce počasí: jasno, polojasno, zataženo, déšť, sněžení

Učitel:  $y = 1$      $y = 2$      $y = 3$      $y = 4$      $y = 5$


Lékařská diagnóza: zdráv(a), rýma, kašel, zácpa, smrt

Klasifikace článků: zprávy, kultura, sport, věda, politika



binární  
umíme


multiclass






# One vs All (One vs Rest)



## Algoritmus klasifikace do více tříd



Převedeme multi-class problém na 3 binární problémy




- Třída 1:
- Třída 2:
- Třída 3:





# One vs All (One vs Rest)

## Algoritmus klasifikace do více tříd



Obecně  $h_{\Theta}^{(i)}(\mathbf{x}) = P(y = i|\mathbf{x}; \Theta)$ , pro  $i \in \{1, 2, 3\}$

Tj. natrénujeme  $i$  binárních logistických regresních klasifikátorů pro každou třídu  $i$  tak, aby predikovaly pravděpodobnost příslušnost vzorku k  $i$ -té třídě.

Při klasifikaci neznámého vzorku vybíráme cílovou třídu  $i$  tak, aby  $\max_i h_{\Theta}^{(i)}(\mathbf{x})$