



Teorie kognitivních systémů

09 Umělé neuronové sítě

- Historie, biologický předobraz
- Matematické modely neuronu
- Neuronová síť, vrstevnaté sítě
- Klasifikace neuronovou sítí
- Cenová funkce
- Optimalizace cenové funkce
- Učení neuronových sítí
- Algoritmus Backpropagation





Umělé neuronové sítě

Úvod

Umělá neuronová síť (*Artificial Neural Network*) – matematický simulační model informačního procesoru inspirovaný biologickými neuronovými sítěmi, zejména lidskou nervovou soustavou a mozkem.

Neuronová síť se skládá z množiny **umělých neuronů**, které mohou být uspořádány do **vrstev** (podle účelu) a navzájem propojeny **synapse**mi, jejichž významnost určují **synaptické váhy**.

Neuronová síť je **adaptivní systém**, který mění svoji strukturu během fáze učení. Modeluje komplexní relace mezi vstupy a výstupy, popř. hledá ve vstupních datech vzory...



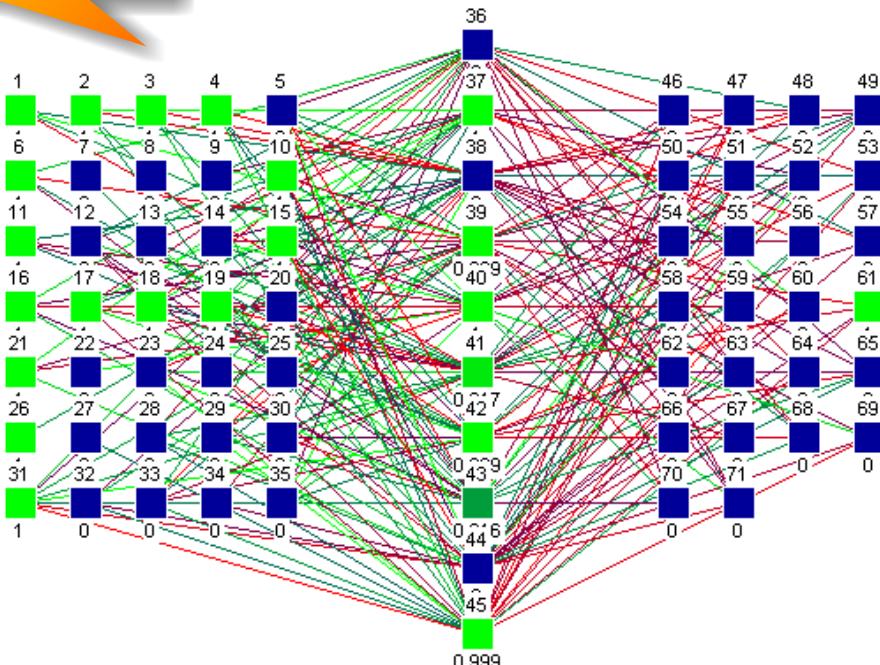


Umělé neuronové sítě

Ilustrační příklad

Neuronová síť je matematický model definující funkci

$$f: \mathbf{x} \in \mathbb{R}^n \rightarrow \mathbf{y} \in \mathbb{R}^m$$





Umělé neuronové sítě

Historický vývoj

- biologický předobraz: Jan Evangelista Purkyně, Ramon y Cajal
- vizionářský článek Američana W. S. McCullocha z roku 1921 o umělém napodobování biologických neuronových sítí
- W. S. McCulloch & W. Pitts představili v roce 1943 první reálně použitelný matematický model neuronu
- D. Hebb, 1949: zákon učení sítí neuronů, konstrukce prakticky použitelných učících algoritmů
- B. Widrow: vrstevnaté sítě ADALINE, MADALINE
- F. Rosenblatt: učící algoritmus pro vrstevnaté sítě s dopředným přenosem signálu
- M. Minsky & S. Papert, 1969: kniha *Perceptrons: An Introduction to Computational Geometry* “dokazuje” omezení jednovrstvé lineární neuronové sítě (perceptronu) → útlum zájmu o problematiku až do konce 80. let 20. stol.





Umělé neuronové sítě

Historický vývoj

- v polovině 80. let 20. stol. dochází k masivní renesanci zájmu o ANN (mj. díky DARPA)
- znovaobjevení algoritmu **back-propagation** (1986) urychlilo rozvoj reálně nasaditelných systémů na bázi ANN
- Kunihiko Fukushima (1980): Neocognitron – „standardní architektura pro počítačové vidění“, práce inspirovaná analýzou funkce buněk primárního vizuálního kortextu
- Cybenko (1989), Hornik (1991) a jiní dokazují (tentokrát již korektně) matematické vlastnosti neuronových sítí
- J. Schmidhuber (2009 – 2012): nové architektury neuronových sítí Recurrent NN a Deep Feedforward NN vyhrávají mj. soutěže v rozpoznávání spojitého rukopisu, analýze textu, ap.





Umělé neuronové sítě

Oblasti úspěšných aplikací

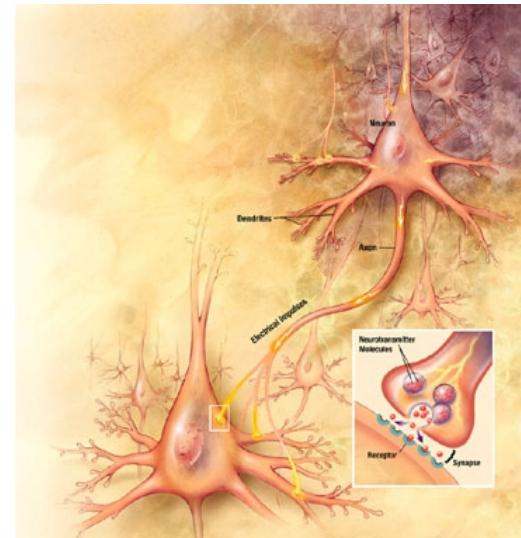
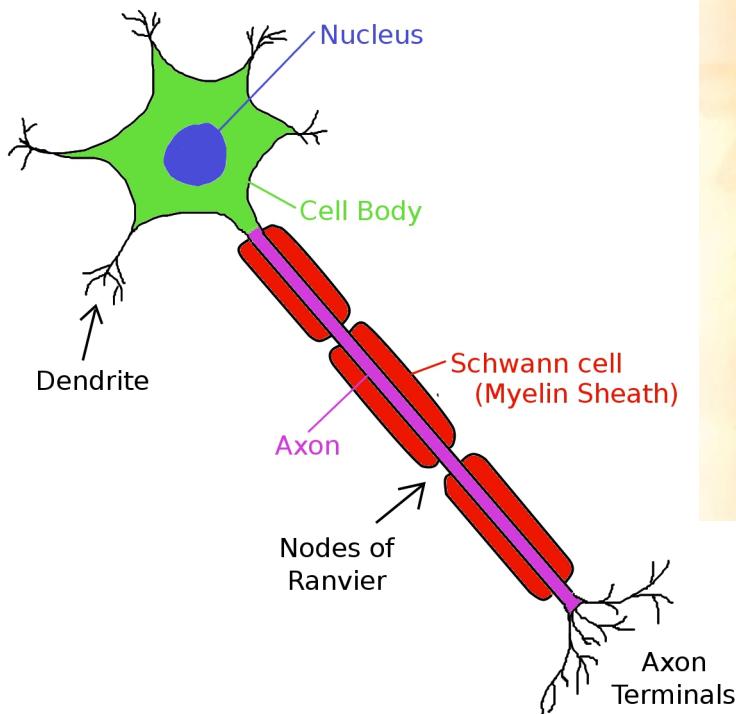
- výzkum v oblasti modelování informačních systémů živých organismů
- výzkum procesů učení, testování, adaptace a generalizace
- predikce časových řad (ekonomie, ekologie, energetika, doprava, meteorologie, logistika)
- analýza signálů (EKG, EEG, akustika, ...)
- de-/komprese a kódování signálů (telekomunikace)
- adaptivní řízení technologických celků
- automatické řízení autonomních systémů
- systémy pro podporu rozhodování a expertní systémy
- modelování komplexních jevů (katastrofy, ekonometrie)
- kontrola kvality a automatické testování
- ...





Biologický neuron

Předobraz matematického modelu



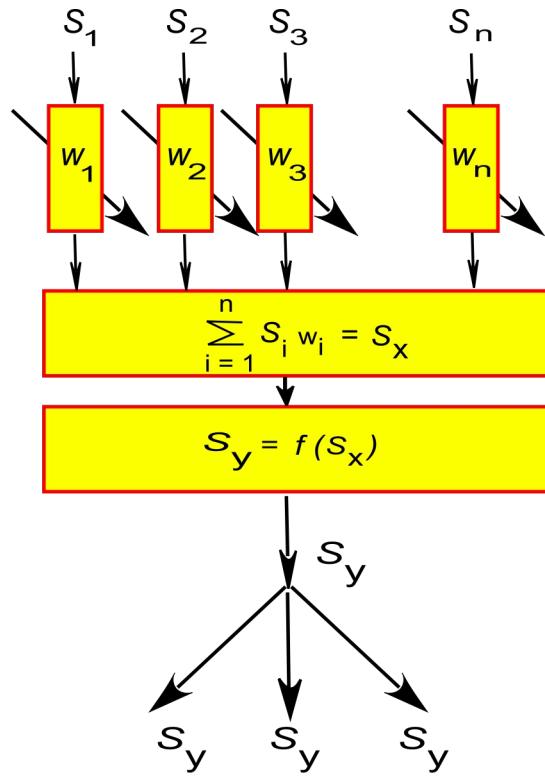
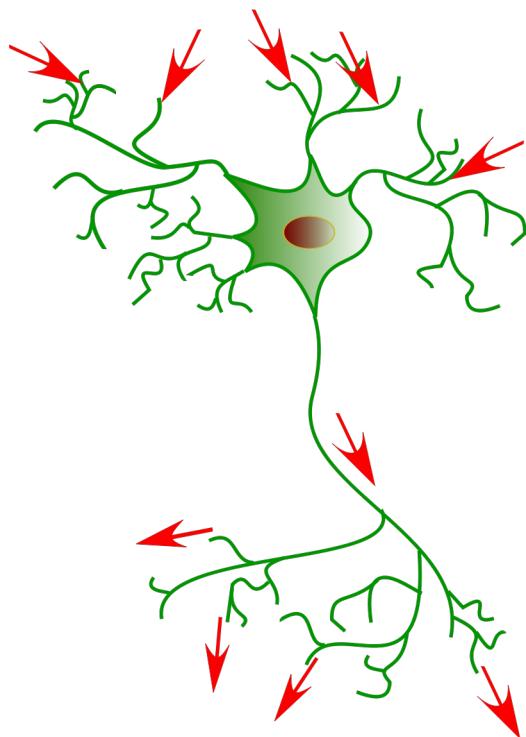
(Obrázek © Wikimedia Commons, Nick Gorton, 2005)

(Obrázek © US National Institutes of Health, National Institute on Aging)



Biologický neuron

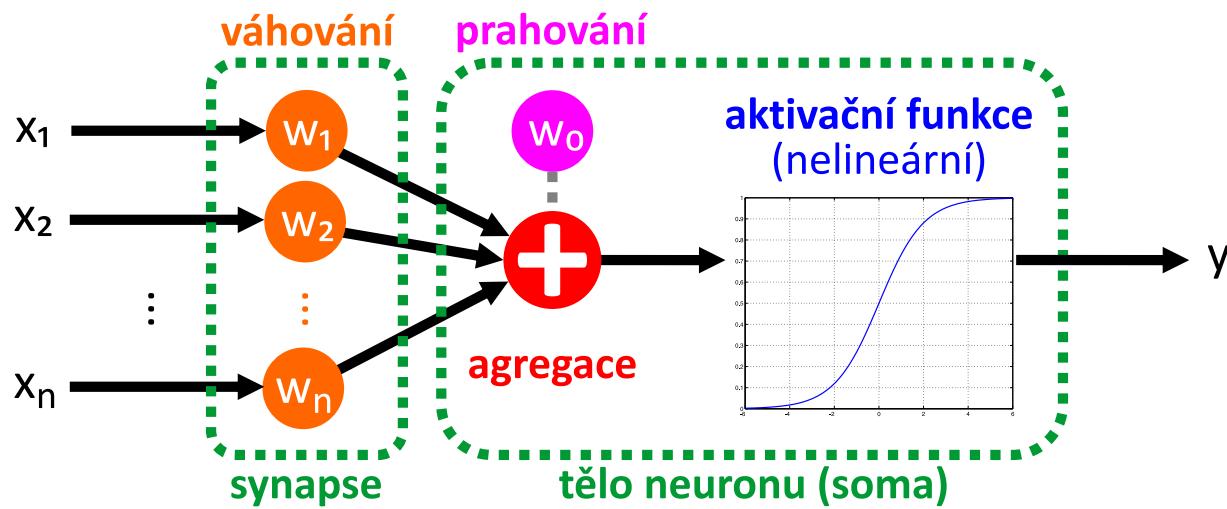
Matematický model





McCulloch-Pittsův neuron

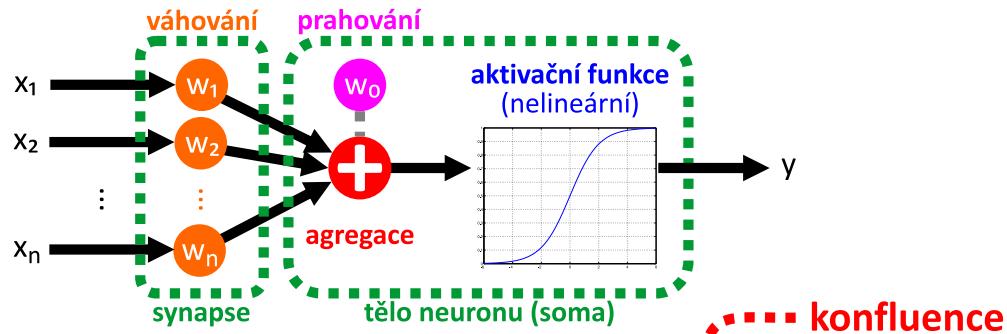
Matematický model umělého neuronu





McCulloch-Pittsův neuron

Matematický model umělého neuronu



Synaptické operace: $z(t) = x(t) \oplus w(t) = (x_i(t) \cdot w_i(t))_{i=1}^n$

Somatické operace:
 $g(z)$

$$\left\{ \begin{array}{l} u(t) = \sum_{i=1}^n z_i(t) \\ v(t) = u(t) - w_0 \\ y(t) = \frac{1}{1 + e^{-v(t)}} \end{array} \right.$$

$$u(t) = \sum_{i=1}^n z_i(t)$$

$$v(t) = u(t) - w_0$$

$$y(t) = \frac{1}{1 + e^{-v(t)}}$$



RBF neuron

Aktivační funkce s radiální bází

LBF (Linear Basis Function)

- dělí vstupní prostor lineárně prostřednictvím n-rozměrných nadrovin

$$u(t) = \sum_{i=1}^n x_i(t)w_i(t)$$

→ standardní McCulloch-Pittsův neuron

Modifikace:

RBF (Radial Basis Function)

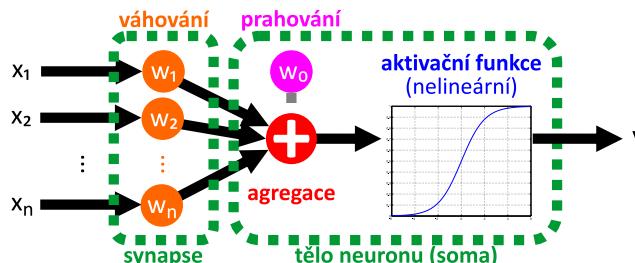
- dělí vstupní prostor prostřednictvím hyperkoulí

$$u(t) = \sqrt{\sum_{i=1}^n (x_i(t) - w_i(t))^2}$$



Umělý neuron

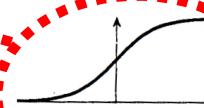
Používané typy aktivačních funkcí



sigmoida je vhodná volba, protože je spojitá, a tedy diferencovatelná v celém R

některé jsou sice výpočetně jednodušší, ale mají jiné nevýhody

Výběr vhodné aktivační funkce závisí na charakteru řešené úlohy...



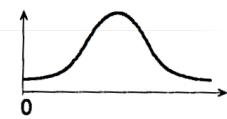
$$y(t) = \frac{1}{1 + e^{-v(t)}}$$

a)



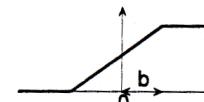
$$y(t) = \tanh v(t)$$

b)



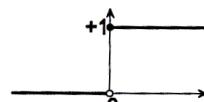
$$y(t) = e^{-v^2(t)}$$

c)



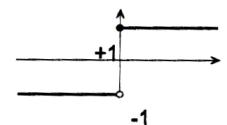
$$\begin{aligned} y(t) &= 0 & v(t) &\leq -b \\ y(t) &= c \cdot v(t) & -b &< v(t) < b \\ y(t) &= 1 & v(t) &\geq b \end{aligned}$$

d)



$$\begin{aligned} y(t) &= 0 & v(t) &< 0 \\ y(t) &= 1 & v(t) &\geq 1 \end{aligned}$$

e)



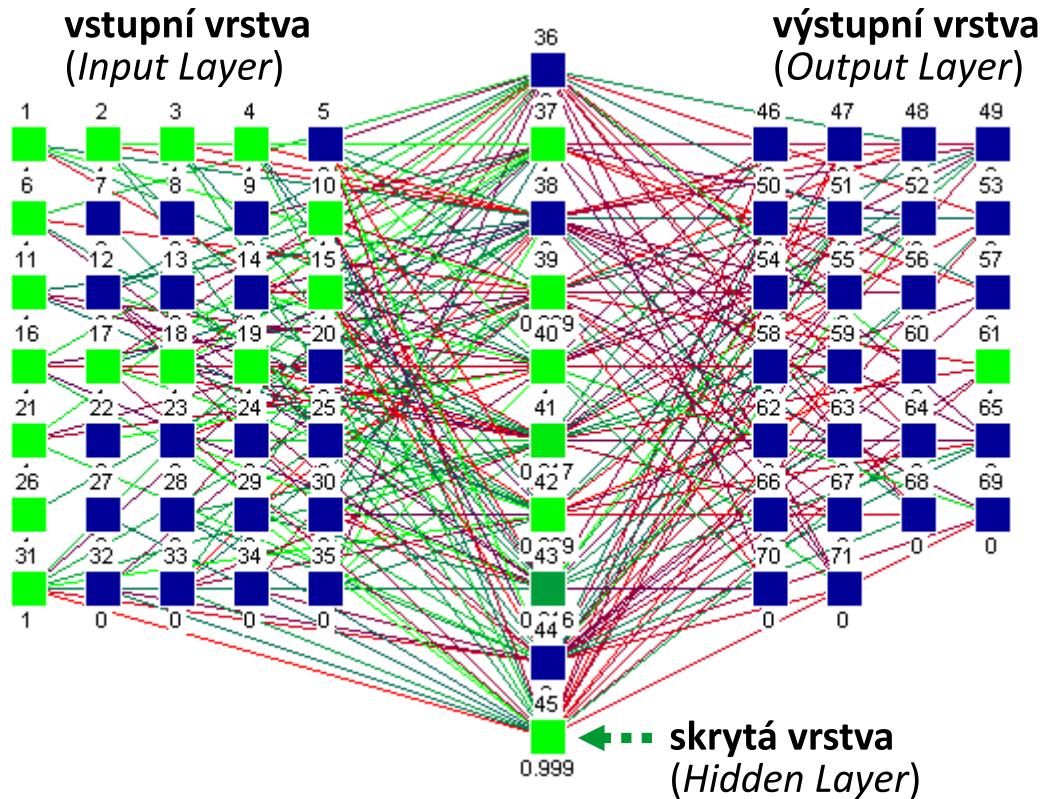
$$\begin{aligned} y(t) &= -1 & v(t) &< 0 \\ y(t) &= 1 & v(t) &\geq 1 \end{aligned}$$

f)



Neuronová síť (Vrstevnatá) struktura z umělých neuronů

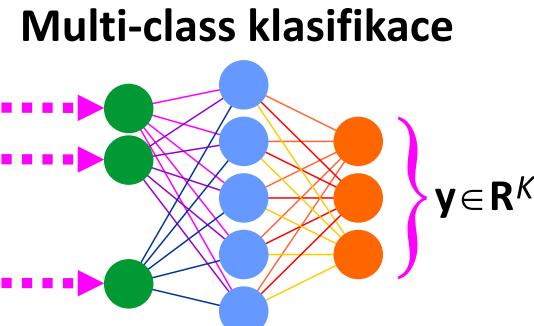
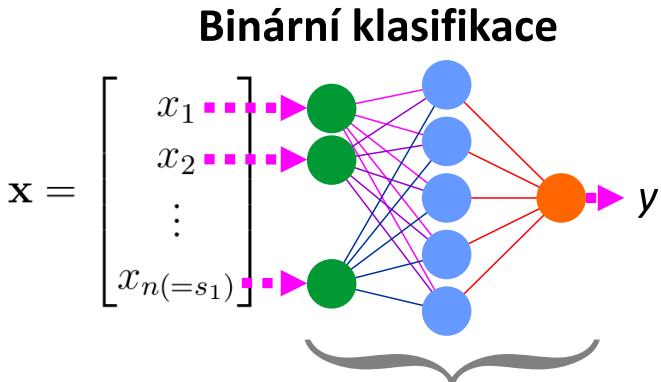
Vícevrstvý perceptron (*Multi-Layer Perceptron, MLP*)





Klasifikace neuronovou sítí

Binární vs multi-class klasifikace



L – celkový počet vrstev sítě
(více než 3 nemá smysl ← Cybenko)

1 neuron ve výstupní vrstvě,
tj. $y = \{0, 1\}$; $h_\Theta(x) \in \mathbb{R}$; počet
neuronů v L -té vrstvě $s_L = 1$,
počet tříd $K = 1$ (aktivace vý-
stupního neuronu indikuje,
zda vzorek do třídy ne-/patří)

K neuronů ve výstupní vrstvě,
tj. $\mathbf{y} = \mathbb{R}^K$; $h_\Theta(x) \in \mathbb{R}^K$; $s_L = K$;

$y = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$ **indikova-**
ná třída $y = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$ $y = \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \end{bmatrix}$ $y = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 1 \end{bmatrix}$



Cenová funkce pro neuronovou síť

Generalizace cenové funkce logistické regrese

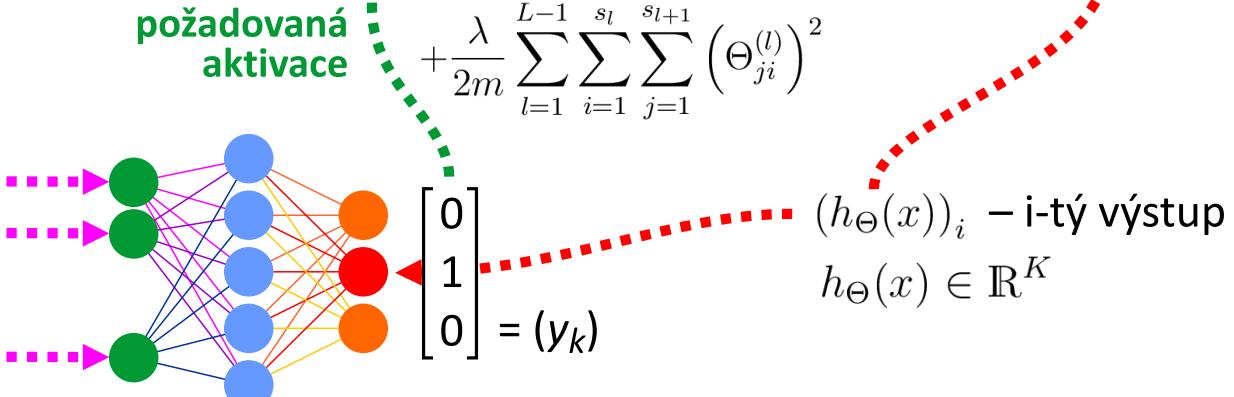
Cenová funkce logistické regrese:

$$J(\Theta) = - \left[\frac{1}{m} \sum_{i=1}^m y^{(i)} \log h_\Theta(\mathbf{x}^{(i)}) + (1-y^{(i)}) \log (1-h_\Theta(\mathbf{x}^{(i)})) \right] + \frac{\lambda}{2m} \sum_{j=1}^n \Theta_j^2$$

Cenová funkce neuronové sítě:

$$J(\Theta) = -\frac{1}{m} \left[\sum_{i=1}^m \sum_{k=1}^K y_k^{(i)} \log (h_\Theta(\mathbf{x}^{(i)}))_k + (1-y_k^{(i)}) \log (1 - (h_\Theta(\mathbf{x}^{(i)}))_k) \right]$$

**požadovaná
aktivace**





Výpočet gradientu

Minimalizace cenové funkce

Cenová funkce neuronové sítě:

$$J(\Theta) = -\frac{1}{m} \left[\sum_{i=1}^m \sum_{k=1}^K y_k^{(i)} \log (h_\Theta(\mathbf{x}^{(i)}))_k + \left(1 - y_k^{(i)}\right) \log \left(1 - (h_\Theta(\mathbf{x}^{(i)}))_k\right) \right] \\ + \frac{\lambda}{2m} \sum_{l=1}^{L-1} \sum_{i=1}^{s_l} \sum_{j=1}^{s_{l+1}} \left(\Theta_{ji}^{(l)}\right)^2$$

Cílem optimalizace je: $\min_{\Theta} J(\Theta)$ – minimalizace cenové funkce...

Potřebujeme umět spočítat:

- $J(\Theta)$
 - $\frac{\partial J(\Theta)}{\partial \Theta_{ij}^{(l)}}$
- }
- pro potřeby formalizace a uvedení do souvislosti s předchozími optimalizačemi jsou váhy w_{ij} přeznačeny na $\Theta_{ij}^{(l)}$
- „přímý“ analytický výpočet – problém





Výpočet parciální derivace $J(\Theta)$

Dopředné šíření (Forward Propagation)

Je-li dán jeden trénovací vzorek (x, y) , pak vektorizovaná verze výpočtu dopředného šíření aktivace sítí vypadá:

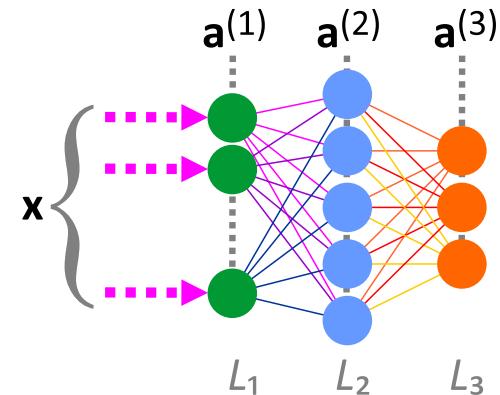
$$\mathbf{a}^{(1)} = \mathbf{x}$$

$$\mathbf{z}^{(2)} = \Theta^{(1)} \mathbf{a}^{(1)}$$

$$\mathbf{a}^{(2)} = g(\mathbf{z}^{(2)}) \quad \text{odečteme práh } a_0^{(2)}$$

$$\mathbf{z}^{(3)} = \Theta^{(2)} \mathbf{a}^{(2)}$$

$$\mathbf{a}^{(3)} = g(\mathbf{z}^{(3)}) = h_{\Theta}(\mathbf{x})$$



→ vypočítá aktivaci všech neuronů v celé síti



Výpočet parciální derivace $J(\Theta)$

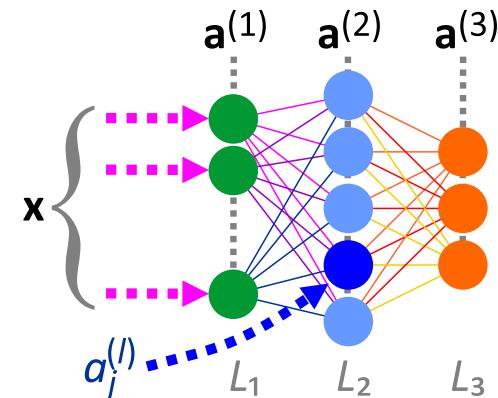
Zpětné šíření (Back-Propagation)

Učící algoritmus **Backpropagation** vlastně provádí numerický výpočet derivace $J(\Theta)$:

$$\delta_j^{(l)} = \text{„chyba“ } j\text{-tého neuronu v } l\text{-té vrstvě}$$

$$\left. \begin{array}{l} \delta_j^{(3)} = a_j^{(3)} - y_j \\ a_j^{(3)} = (h_\Theta(\mathbf{x}))_j \end{array} \right\} \text{pro vstupní vrstvu}$$

$$\delta^{(2)} = (\Theta^{(2)})^T \delta^{(3)} \cdot * \frac{dg(\mathbf{z}^{(2)})}{d\mathbf{z}^{(2)}} \quad \left\{ \text{pro skrytou vrstvu} \right.$$



Vektor chyb $\delta^{(1)}$ neexistuje – jsou to přímo vstupy do sítě, tj. nelze mluvit o chybě...



Výpočet parciální derivace $J(\Theta)$

Souvislost zpětného šíření s par. deriv. $J(\Theta)$

Derivace aktivační funkce:

$$\frac{dg(\mathbf{z}^{(l)})}{d\mathbf{z}^{(l)}} = \mathbf{a}^{(l)} * (1 - \mathbf{a}^{(l)}) \equiv \frac{d\sigma(x)}{dx} = \sigma(x)(1 - \sigma(x))$$

protože

$$s(x) = \frac{1}{\sigma(x)} = 1 + e^{-x} \quad s'(x) = \frac{-\sigma'(x)}{\sigma(x)^2}$$

$$s'(x) = -e^{-x} = 1 - s(x) = 1 - \frac{1}{\sigma(x)} = \frac{(\sigma(x) - 1)}{\sigma(x)}$$

Použitím poměrně komplikované matematiky lze ukázat, že

$$\boxed{\frac{\partial J(\Theta)}{\partial \Theta_{ij}^{(l)}} = a_j^{(l)} \delta_i^{l+1}}$$

za předpokladu ignorování regularizačního parametru, tj. $\lambda = 0$.





Algoritmus Backpropagation

Optimalizace L -vrstvé neuronové sítě

Trénovací množina $\{(\mathbf{x}^{(1)}, \mathbf{y}^{(1)}), (\mathbf{x}^{(2)}, \mathbf{y}^{(2)}), \dots, (\mathbf{x}^{(m)}, \mathbf{y}^{(m)})\}$

Nastavíme $\Delta_{ij}^{(l)} \leftarrow 0, \forall i, j, l$

for $i \leftarrow 1 \dots m \{$

$\mathbf{a}^{(1)} \leftarrow \mathbf{x}^{(i)}$

 výpočet dopředného šíření, abychom získali $\mathbf{a}^{(l)}$ pro $l = 2, \dots, L$

 výpočet chyby ve výstupní vrstvě $\delta^{(L)} \leftarrow \mathbf{a}^{(L)} - \mathbf{y}^{(i)}$

 výpočet zpětného šíření chyby $\delta^{(L-1)}, \delta^{(L-2)}, \dots, \delta^{(2)}$

$\Delta_{ij}^{(l)} \leftarrow \Delta_{ij}^{(l)} + a_j^{(l)} \delta_i^{(l+1)}$

}

$$D_{ij}^{(l)} \leftarrow \frac{1}{m} \Delta_{ij}^{(l)} + \lambda \Theta_{ij}^{(l)} \quad \text{jestliže } j \neq 0 \quad \Bigg\}$$

$$D_{ij}^{(l)} \leftarrow \frac{1}{m} \Delta_{ij}^{(l)} \quad \text{jestliže } j = 0 \quad \Bigg\}$$

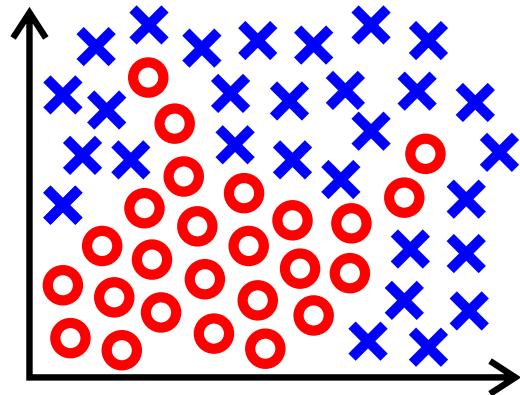
$$\frac{\partial J(\Theta)}{\partial \Theta_{ij}^{(l)}} = D_{ij}^{(l)}$$





Použití neuronových sítí

Motivace – nelineární klasifikace





Další typy neuronových sítí

Náměty k samostudiu

- **SOM** (*Self-Organizing Map*), též **Kohonenova síť**
- **LAM** (*Linear Associative Memory*)
- **ART** (*Adaptive Resonance Theory*)
ART 1, 2, 2-A, 3, Fuzzy ART, ARTMAP
- **Cognitron** a **Neocognitron**
- **Hopfieldova síť**
- **ADALINE/MADALINE**

